

# SEAGAS 修复日志：合成学生重名

分支 fix/unique-student-names · 提交 fe8acff (已合并到 dev) · 2026-10-01 · Ng Yong Hin

## 1. 摘要

5,000 名合成学生原来只有 **1,360** 个不同名字，**4,240** 人 (84.8%) 和别人同名，最常见的 Khoo Zi Xuan 出现 16 次，顾问仪表板的学生列表里很难区分。修复后 5,000 个名字全部唯一（忽略大小写和多余空格）。除了 3,641 个学生的 full\_name，其他数据（UUID、技能、GPA、项目、证书、密码哈希）与修复前逐字节相同。

| 指标                   | 修复前               | 修复后   |
|----------------------|-------------------|-------|
| 不同名字数                | 1,360             | 5,000 |
| 与他人同名的学生             | 4,240 (84.8%)     | 0     |
| 同一名字最多出现次数           | 16 (Khoo Zi Xuan) | 1     |
| 改了名字的学生              | —                 | 3,641 |
| 其他 CSV / 覆盖率 / 各族群人数 | —                 | 全部不变  |

## 2. 问题原因

data/generate\_synthetic\_data.py 里 make\_name() 的名字池太小：

| 族群     | 原名字池                   | 学生数   |
|--------|------------------------|-------|
| 华裔     | 20 个姓 × 20 个名 = 400 种  | 2,744 |
| 马来 (男) | 10 个名 × 10 个父名 = 100 种 | 727   |
| 马来 (女) | 10 个名 × 10 个父名 = 100 种 | 762   |
| 印裔、国际  | Faker 生成               | 767   |

直接换成更大的名字池不可行：rng.choice() 消耗多少随机数取决于列表长度，一换池子，主随机数 rng 的序列就会偏移，后面每个学生的技能、GPA、项目都会跟着变。Faker 的随机数又和生成项目名的 fk.company() 共用，同样不能多抽。

## 3. 修复方法

思路：生成过程完全不动，等全部学生生成完以后，再用一个独立的随机数去重。

- **make\_name() 不改抽取方式**：调用位置不变，仍从原来的小名字池抽，主 rng 和 Faker 的抽取次数完全不变；只是多返回族群（马来名字再加性别）：(name, ethnicity, gender)。
- **新增更大的名字池**（只用于重抽），全部是罗马化的马来西亚常见名字，每个池的组合数都超过该族群学生数的 10 倍（见下表）。
- **unique\_names() 去重**：用独立的 random.Random(f"names-{seed}") 按学号顺序检查；名字（忽略大小写和多余空格）已经有人用，就从同族群、同性别的新池重抽，直到不重复。印裔和国际学生用另外两个调用过 seed\_instance() 的 Faker 实例重抽，不碰原来的 fk / fk\_in。
- **屏蔽真实人物**：BLOCKED\_NAMES 列出新池能拼出的公众人物全名（如 Tan Kok Wai），命中就当作重名重抽；华裔名字的音节也不能和姓相同（避免 “Leong Leong Rui”）。
- **结束前自检**：generate() 返回前再检查一次，名字不唯一就 SystemExit 报错退出。

| 新名字池    | 组成                           | 组合数     | 学生数   | 倍数  |
|---------|------------------------------|---------|-------|-----|
| 华裔      | 50 个姓 × 48 个音节两两组合 (音节≠姓)    | 112,424 | 2,744 | 41× |
| 马来 (男)  | 16 前段 × 22 后段 × 46 父名, bin   | 16,192  | 727   | 22× |
| 马来 (女)  | 16 前段 × 22 后段 × 46 父名, binti | 16,192  | 762   | 21× |
| 印裔 / 国际 | 独立种子的 Faker en_IN / en_US    | —       | 767   | —   |

## 4. 改动文件 (提交 fe8acff)

| 文件                                        | 改动                                                             |
|-------------------------------------------|----------------------------------------------------------------|
| data/generate_synthetic_data.py           | 新名字池、make_name() 多返回族群、unique_names()、屏蔽名单、唯一性自检 (+112 / -8 行) |
| tests/test_synthetic_data.py              | 新增: 5000 人 seed 42 名字全部唯一且不含屏蔽名; 同 seed 两次输出完全一样               |
| data/output/users.csv                     | 只有 3,641 行的 full_name 变化                                       |
| data/output/seed_synthetic_students.sql   | 只有对应的名字和表头生成时间变化                                               |
| data/output/summary_stats.txt             | 只有 Generated 时间一行变化                                            |
| data/README_synthetic.md                  | 补一句: 5,000 个名字全部唯一                                             |
| docs/report_drafts/dataset_description.md | 第 2.2 节补一句: all 5,000 names are unique                         |

其余 5 个输出文件 (student\_profiles / student\_skills / student\_projects / student\_certifications / students\_meta) 与修复前逐字节相同, 所以不在提交里。

## 5. 改名示例

每个名字第一次出现的学生保留原名, 之后重复的学生改名, 族群和性别不变。例如原来 16 个 Khoo Zi Xuan, 现在只有 student0109 保留这个名字。

| 学号          | 原名                         | 新名                         |
|-------------|----------------------------|----------------------------|
| student0046 | Faris Iskandar bin Zainal  | Adam Rayyan bin Omar       |
| student0054 | Chong Ming Jun             | Lai Ting Kok               |
| student0066 | Ng Kai Wen                 | Sim En Han                 |
| student0096 | Balqis Humaira binti Ahmad | Hannah Qistina binti Hamid |
| student0101 | Chan Kok Leong             | Tee Xin Shan               |
| student0106 | Luqman Hakim bin Kamarudin | Mohd Fikri bin Mokhtar     |
| student0263 | Khoo Zi Xuan               | Chan Chun Yong             |
| student1162 | Khoo Zi Xuan               | Lum Ting Kok               |

另有 1 个学生 (student0651) 原名本来不重复, 但已被前面学生的重抽结果占用, 按 “已有人用就重抽” 的规则也改了名: Soh Li Ying → Teoh Shu En。所以改名人数是  $3,641 = 3,640$  个重复名 + 1。

## 6. 验收结果

| 验收项                       | 结果                        |
|---------------------------|---------------------------|
| 5000 个名字全部唯一 (忽略大小写和多余空格) | <b>通过</b> : 5,000 / 5,000 |

| 验收项                                                       | 结果                                                                                   |
|-----------------------------------------------------------|--------------------------------------------------------------------------------------|
| git diff 里除了 users.csv 的 full_name、SQL 里的名字和生成时间，其他内容没有变化 | <b>通过</b> ：另外 5 个 CSV 逐字节相同；users.csv 其他列 0 行变化；SQL 无其他差异行                           |
| summary_stats.txt 覆盖率仍是 89.8% / 71.6% / 39.7%             | <b>通过</b>                                                                            |
| 各族群人数和修复前一样（按 make_name() 返回的族群）                          | <b>通过</b> ：华裔 2,744、马来男 727、马来女 762、印裔 + 国际 767；每个新名字都在原族群                           |
| pytest tests/ 全部通过                                        | <b>通过</b> ：14 passed（原有 12 + 新增 2）；合并到 dev 后重跑仍 14 passed                            |
| 重新导入后 student0001 能登录，顾问仪表盘学生列表没有重名                       | <b>通过</b> ：/api/auth/login 200；/api/advisor/students 5,000 行无重名；库内名字与 users.csv 完全一致 |

另外验证了 make\_name() 在去重前给出的 5,000 个名字与修复前完全一致，证明主随机数和 Faker 的抽取次数没有改变；并用不同 PYTHONHASHSEED 跨进程运行，输出一致。

## 7. 复核与已知限制

提交前做了一轮独立复核（对照计划书、代码正确性、名字内容三个角度）。已处理：

- 重抽出真实政治人物全名 Tan Kok Wai → 加入屏蔽名单后重新生成。
- 4 个名字的音节和姓重复（如 Leong Leong Rui）→ 重抽时排除与姓相同的音节。
- 一处多余的空格改动和不准确的 docstring → 已修正。

未处理（不影响验收，可后续再定）：

- 旧名字池里的 “Siti Nurhaliza”（知名歌手的名字，10 名学生使用）：改旧池会打乱其他数据，所以保留；新池不含这个名字。
- 部分重抽的华裔名字音节顺序不太自然（如 “Keong” 放在第一个音节）。
- Faker 英文名带 MD、Jr. 等后缀，修复前就有。
- make\_name() 仍从旧小池抽，所以每个名字第一次出现时还是旧池里的名字；这是保证其他数据不变的唯一做法。

## 8. 组员需要做的

backend/start\_backend.bat 只在数据库里没有合成学生时才导入，所以要先删除旧数据：

```
psql -U postgres -d seagas_db -f data/delete_synthetic_data.sql
backend\start_backend.bat
```

删除会级联删掉合成学生的 assessment 和 recommendation。重新生成数据需要 Faker（本次用 40.40.0，能逐字节复现已提交的输出）：pip install faker bcrypt。