# SEAGAS Sprint 2 Work Summary — Ng Yong Hin

Oct 16, 2026 · @Ng Yong Hin

## 总览

Sprint 2（9 月 26 日到 10 月 16 日）我负责 AI / NLP 和数据集，也帮忙做了一部分后端。完成的工作分两块：

- **数据层：**5,000 名合成学生、扩充到 138 个技能的技能库、6 个职位共 152 条技能对应，以及 65 条真实 JD。
- **NLP 模块：**keyword、semantic、hybrid 三种技能抽取，Strong / Developing / Gap 匹配，以及 L1 和 L2 的对比。

Sprint 2 backlog 里我名下的 S2-01、S2-02、S2-16 及其子任务都已完成，和 Carl 共同负责的 S2-11、S2-12 里我的部分也已完成。把 NLP 接进 `jobs.py` 和 `assessments.py` 由 Carl 做；接口文档和可直接替换的代码已经交给他。这个 sprint 我一共提交了 30 个 commit，其中 10 个 PR 已合并进 `dev`。

- **项目：**COS40005 Computing Technology Project A，Group 10（POC004）
- **仓库：**GitHub `Group10_ProjectA`，开发分支 `dev`（现在在 `f4befca`）
- **当前阶段：**Sprint 2（Week 8–10），Sprint 2 report 10 月 24 日截止
- **主要文档：**`docs/NLP_INTERFACE.md`、`docs/NLP_CLASSIFICATION_RULES.md`、`nlp/experiments/THRESHOLDS.md`、`docs/report_drafts/`

### 主要成果数字

| 项目 | 结果 |
|---|---|
| 技能库 | 从 32 个扩充到 138 个技能，共 356 个 alias；以一份 CSV 为唯一来源，自动生成数据库 seed 和 NLP 用的 taxonomy |
| 职位技能对应 | 6 个职位共 152 条，分 required / preferred / bonus 三档 |
| 合成学生 | 5,000 名学生、78,327 条技能记录，名字全部唯一，同一个 seed 能逐字节复现；strong / average / weak 三类学生的核心技能覆盖率分别为 89.8% / 71.6% / 39.7% |
| 真实 JD 数据集 | 65 条（每个职位 10–13 条），来自 JobStreet 和 Indeed Malaysia，已清洗并匿名化 |
| Brief 例子 JD（7 个技能） | L1 keyword 找到 6 个，L2 semantic 找到 4 个，hybrid 7 个全部找到 |
| 65 条 JD 上的抽取结果 | 平均每条 JD 找到的技能数：keyword 9.2、semantic 7.3、hybrid 11.2；每条耗时：keyword 约 1 ms，semantic / hybrid 约 0.12–0.16 s |
| 语义阈值 | MATCH 0.60、RELATED 0.50，用 60 对人工标注的短语–技能对选出（F1 0.929） |
| 测试 | `python -m pytest nlp/tests tests -q`：321 passed、4 xfailed（含模型测试） |

## Sprint 2 任务状态

任务编号沿用 Sprint 2 report 的 backlog。

| 编号 | 任务 | 状态 | 证据 |
|---|---|---|---|
| S2-01 | NLP 模块 + Level 1 关键词匹配 | **完成** | PR #8、#9；`nlp/extractor.py` |
| S2-01-01 | 定义 NLP 输入输出接口 | **完成** | PR #8；`nlp/types.py`、`docs/NLP_INTERFACE.md` |
| S2-01-02 | 测试 L1：精确匹配、别名、未命中 | **完成** | PR #9；brief 例子 6/7，漏掉的 Critical Thinking 用 xfail 测试记录了原因 |

| | | | |
|---|---|---|---|
| S2-02 | Level 2 语义匹配（Sentence Transformers）+ Hybrid | **完成** | PR #11、#12、#13；`nlp/model.py`、`extract_hybrid()` |
| S2-02-01 | 定语义阈值 | **完成** | PR #12；`nlp/experiments/THRESHOLDS.md` |
| S2-02-02 | L1 和 L2 输出对比 | **完成** | commit `f42a00f`（PR 待开）；`docs/report_drafts/method_comparison.md` |
| S2-11-01 / 02 | 计分逻辑说明；用合成学生测试 readiness score（与 Carl 共同负责） | **我的部分完成** | PR #13；规则文档第 6 节；测试结果为 strong > average > weak。加权计分由 Carl 在 PR #7 完成 |
| S2-12 / 01 / 02 | Strong / Developing / Gap 的规则、阈值和测试（与 Carl 共同负责） | **我的部分完成** | PR #13；`nlp/matcher.py`、`docs/NLP_CLASSIFICATION_RULES.md`。接入 `assessments.py` 由 Carl 做 |
| S2-16 / 01 / 02 | 收集、清洗、验证 JD（每个职位至少 10 条） | **完成** | PR #10；`data/jd_dataset/DATASET_SUMMARY.md` |

# Sprint 2 工作记录

| 日期 | 工作 | PR / commit | 测试结果 |
|---|---|---|---|
| 26 Sep | 生成 5,000 名合成学生（seed 42）；写一键启动脚本 `start_backend.bat`；修好 `requirements.txt`；6 个职位的技能 seed | PR #2、#4、#5 | 在本机 PostgreSQL + FastAPI 上测通：登录和 profile API 返回 200 |
| 29 Sep | 技能库 v2（138 个技能，CSV 唯一来源，修好 alias 冲突）；职位技能更新到 152 条；按新技能库重新生成学生；JD 工具链（ingest、频率分析、gold 抽样）；`start_all.bat`；报告 Dataset 章节草稿 | PR #6、`7340983` | 在全新数据库上完整跑通；pytest 全过 |
| 1 Oct | 修合成学生重名：不同名字从 1,360 个增加到 5,000 个，其他数据逐字节不变；review 并合并 Carl 的推荐引擎 | `fe8acff`、PR #7 | 14 passed；advisor 学生列表里没有重名 |
| 8 Oct | NLP 公共接口：类型定义、技能目录加载、文本规范化；接口文档交给 Carl | PR #8 | 接口测试通过 |
| 12 Oct | L1 关键词抽取：词边界、alias、英美拼写、歧义词按上下文判断；建立 65 条真实 JD 数据集 | PR #9、#10 | brief 例子 6/7；5,000 字的 JD 抽取不到 50 ms |
| 14 Oct | L2 语义抽取：spaCy 生成候选短语 + all-MiniLM-L6-v2；模型只加载一次，技能 embedding 缓存到磁盘 | PR #11、#12 | semantic 单独使用时 brief 例子 4/7 |
| 15 Oct | 用 60 对人工标注定阈值；实现 hybrid 抽取和 `match_skills()`；写分类规则文档；做与现有后端逻辑的 before / after 对比；在 65 条 JD 上做 L1 / L2 / hybrid 对比 | PR #12、#13、`f42a00f` | 321 passed、4 xfailed；brief 例子 hybrid 7/7 |

# NLP 结果

### 三种抽取方法（65 条 JD，S2-02-02）

| 方法 | 每条 JD 技能数（平均） | Brief 例子 | 每条 JD 耗时（中位数） |
|---|---|---|---|
| Keyword（L1） | 9.2 | 6 / 7 | 0.7 ms |
| Semantic（L2） | 7.3 | 4 / 7 | 164 ms |
| Hybrid | 11.2 | 7 / 7 | 159 ms |

- **两种方法的一致程度一般**：keyword 和 semantic 的 Jaccard 平均 0.51。713 个"JD–技能"对中，51% 两种方法都找到，33% 只有 keyword 找到，16% 只有 semantic 找到。
- **Hybrid 补回了漏掉的技能**：在 58 条 JD 里比 keyword 多找到 129 个技能。最多的是 "good analytical and problem-solving skills" 这类并列列表里的 Critical Thinking（21 条 JD），而 L1 和 L2 单独使用时都找不到。
- **两种方法各有典型错误**：semantic 会把 SQL 这类精确技能名打在 0.59，刚好低于阈值而漏掉；也会把泛词配到具体工具上，如 "testing" → A/B Testing（14 条 JD）。keyword 会被太宽的别名误配，如 "initiatives" → Self-Motivation（9 条 JD）。
- **没有算 P / R / F1**：还没有人工 gold 标注，所以这一轮只是初步对比，不是准确率评估。

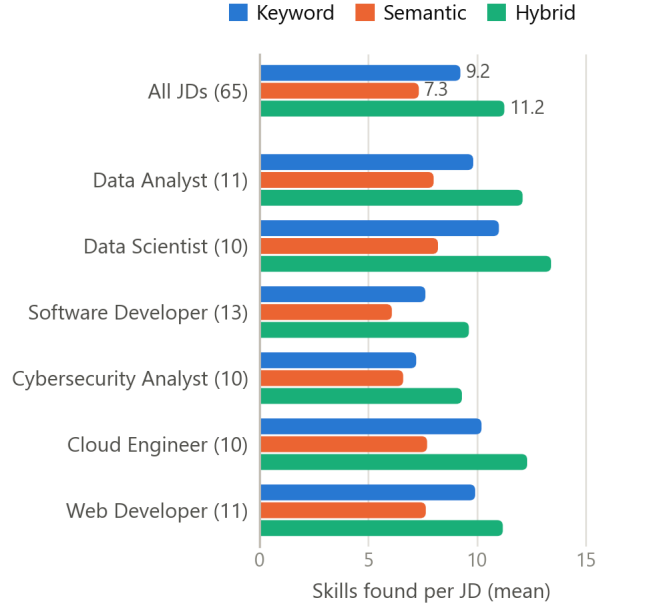



图 1：各职位每条 JD 平均找到的技能数（三种方法）

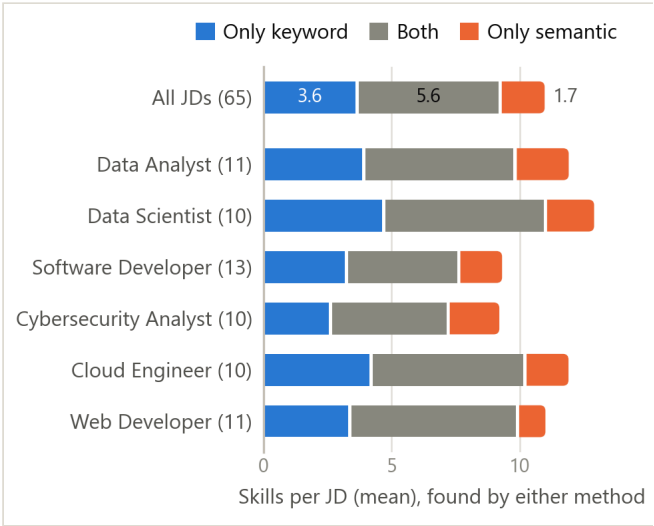



图 2：只有 keyword 找到 / 两种都找到 / 只有 semantic 找到（每条 JD 平均）

### 匹配与评分（S2-11、S2-12）

- **分类规则**：同一个技能，且学生的熟练度为 intermediate 或 advanced 或者有证据，记为 Strong；beginner 且没有证据，或者只有相关技能（相似度 0.50–0.60），记为 Developing；其他记为 Gap。每条结果都附带相似度、触发匹配的学生技能，以及一句用模板生成的英文理由。
- **合成学生的分数顺序合理**：Data Analyst 代表学生 70.0 > 56.0 > 34.0，Cybersecurity Analyst 70.7 > 53.5 > 24.1（strong > average > weak），hybrid 下也一样。
- **和现有后端逻辑的对比**（200 名学生 × 6 个职位，共 30,400 行）：
  - 3,053 行（10.0%）的判定改变。
  - 修掉了 1,872 行子串误判，比如 R 被当成包含在 "Docker" 里，Java 被当成包含在 "JavaScript" 里。
  - 代价是 305 行真正相关的技能（如 SQL 和 PostgreSQL）从 Developing 变成了 Gap。

- 8.9% 的评估分数变动超过 10 分。

## Git 分支与 PR 状态

| 分支 | PR | 状态 |
|---|---|---|
| `feature/synthetic-data` | #2 | 已合并（26 Sep） |
| `fix/requirements` | #4 | 已合并（28 Sep，Carl 合并） |
| `feature/job-role-skills` | #5 | 已合并（26 Sep） |
| `feature/skills-library-v2` | #6 | 已合并（29 Sep） |
| `fix/unique-student-names` | — | 已进 `dev`（1 Oct） |
| `feature/nlp-interface` | #8 | 已合并（10 Oct） |
| `feature/nlp-keyword` | #9 | 已合并（12 Oct） |
| `feature/jd-dataset` | #10 | 已合并（13 Oct） |
| `feature/nlp-semantic` | #11、#12 | 已合并（14、15 Oct） |
| `feature/nlp-matcher` | #13 | 已合并（15 Oct） |
| `feature/nlp-compare` | — | **已 push（`f42a00f`），PR 待开** |

## 已知问题和需要决定的事

| # | 事项 | 现在的情况 | 找谁 |
|---|---|---|---|
| 1 | NLP 还没接进后端 | 网页上提交 JD 和跑评估，用的还是旧的子串匹配。可以直接替换的代码在 `docs/NLP_INTERFACE.md` 第 6 节 | Carl |
| 2 | 还没有 gold 标注 | `gold_labels.csv` 只有表头，所以没有 Precision / Recall / F1；对比脚本已经支持，标注好后会自动计算 | 我自己（Sprint 3–4） |
| 3 | 三个规则提案 | A：两个不同技能相似时，最多算 Developing（现在 Teamwork ← Leadership 0.600 会被算成 Strong）。B：同一类工具算 Developing（Tableau 对 Power BI 只有 0.251）。C：beginner 只有 coursework 时算 Developing。都还没实现 | 全组 |
| 4 | 语义误配和别名缺口 | 泛词被配到具体工具上（testing、analytics、database、programming languages）；技能库缺 "UI/UX"、"firewalls" 等 alias | 我自己 |
| 5 | Sprint 2 backlog 表还没更新 | Sprint2.docx 里我名下的任务还写着 Not Started / 0 小时，要在 10 月 24 日前改好 Status 和 Act. hrs | 我自己 |

## 下一步（Sprint 3）

1. 开 `feature/nlp-compare` → `dev` 的 PR，把对比结果放进 Sprint 2 report 的证据部分。
2. 和 Carl 一起把 `extract_skills()` 接进 `jobs.py`、把 `match_skills()` 接进 `assessments.py`，再在网页上走一遍完整流程。
3. 和组员决定规则提案 A / B / C，补上缺的 alias，过滤一个词的泛词候选。
4. 人工标注 60 条 gold JD（请一位组员另标 12 条，算 Cohen's κ），为 Sprint 4 的 P / R / F1 评估做准备。
5. 用公开 API 把 JD 扩充到每个职位至少 30 条，再跑一次对比，并按频率分析调整职位技能。

6. 为合成学生批量跑评估，让顾问仪表板有真实数据。

## Sprint 2 Reflection

**Summary.** In Sprint 2 I delivered SEAGAS's data layer and its NLP module. The data layer covers 5,000 synthetic students, a 138-skill library, 152 role-skill links and 65 real job descriptions. The NLP module covers keyword, semantic and hybrid extraction and a Strong / Developing / Gap matcher with explanations. All my backlog items are done, and ten PRs are merged into `dev`. The comparison branch is pushed, and its PR is still to be opened.

**What went well.** Agreeing the interface first let Carl plan the integration while I built the internals. Choosing thresholds from hand-labelled pairs and writing known failures as strict xfail tests kept the claims honest. On the brief's own example, the numbers show L1 at 6/7 and hybrid at 7/7. Measuring before and after on the same students made the effect of each rule visible.

**Challenges.** Semantic similarity alone was weaker than expected: exact names such as SQL score just below the threshold, and some generic words land on specific tools. Related tools were the opposite problem: Tableau and Power BI score only 0.25. Hybrid needed an extra step for coordinated lists ("analytical, communication and problem-solving skills") to reach 7/7. Without gold labels, the comparison can show where the methods disagree, but not which one is right.

**Lessons.** Keep a hand-made reference separate from the system being measured. Run every rule on real data before trusting it. Small fixtures and strict tests catch regressions early. Documents written for teammates, such as the interface contract and the rules table, save more time than they cost.

**Next sprint.** Integrate NLP into the backend with Carl, decide the three rule proposals, label the gold set, grow the JD collection to 30 or more per role, and run batch assessments for the advisor dashboard.