

SEAGAS Work Log — Ng Yong Hin (Part 3)

Sep 29, 2026 · @Ng Yong Hin

总览

9月29日完成了 Sprint 2 技能库与数据集方案的 Phase 0-5：技能库从 32 个扩充到 **138 个**，6 个职位的技能对应更新为 152 条，5000 个合成学生按新技能库重新生成，JD 数据集的工具链也已做好。全部都在本机 PostgreSQL 和 FastAPI 上测试通过，并在一个临时的全新数据库上完整跑过一遍。真实 JD 数据还没收集，目前用虚构的示例数据测通了流程。

- **项目**：COS40005 Computing Technology Project A, Group 10
- **仓库**：GitHub `Group10_ProjectA`，分支 `feature/skills-library-v2`（已 push，PR 待开）
- **当前阶段**：Sprint 2（Week 9-10）
- **执行方案**：`docs/SPRINT2_SKILLS_DATASET_PLAN.md`

29 Sep 2026 工作记录

时间	工作	文件	测试结果
22:19	文档和一键启动：技能库 README、合成数据 README、报告「Dataset description」草稿（英文，IEEE 引用）； <code>start_backend.bat</code> 改成每次都跑两个可重复执行的技能 seed（旧数据库也能升级），有 JD 数据时自动导入	<code>data/skills/README.md</code> 、 <code>data/README_synthetic.md</code> 、 <code>docs/report_drafts/dataset_description.md</code> 、 <code>backend/start_backend.bat</code>	全新临时数据库上 schema → 技能库 138 → 职位技能 152 → 5000 学生（78,327 条技能）→ JD 全部成功； <code>.bat</code> 冒烟测试每一步都过；GET <code>/api/students/skills-library</code> 返回 138 个
22:18	把 Serverless 改成 AI_Digital，让云领域技能都在同一个 category	<code>data/skills/skills_library.csv</code>	pytest 全过；技能库 88 Technical / 21 AI_Digital / 15 Analytical / 14 Soft
22:17	JD 数据集工具链：导入清洗（Kaggle CSV、手动 txt，预留 Phase 6 的 API JSON 接口）、技能频率分析、gold 样本和标注指南、导入数据库；另把 Go、Excel、REST 这类容易误判的词移到 ambiguous	<code>data/jd_dataset/</code> 、 <code>tests/test_jd_pipeline.py</code>	虚构示例上跑通：去重、过滤太短、跳过 senior、去掉邮箱/电话/公司名都正常；导入第二次插入 0 条；pytest 12 个全过
22:06	合成学生生成器改读技能库 CSV，职位核心技能直接从 <code>seed_job_role_skills.sql</code> 读；加入 Security+、CEH、CCNA、AWS SAA、CKA 等 25 个证书和新项目；重新生成 5000 个学生	<code>data/generate_synthetic_data.py</code> 、 <code>data/output/</code>	strong / average / weak 核心技能覆盖率 89.8% / 71.6% / 39.7%；138 个技能全部被用到；同一个 seed 输出完全一致； <code>student0001</code> 登录和 GET <code>/api/students/profile</code> 返回 200

时间	工作	文件	测试结果
22:02	更新 6 个职位的技能对应：每个 9-10 required、8-10 preferred、6-8 bonus；Cybersecurity Analyst 换成真正的安全技能	database/seed_job_role_skills.sql	跑两次都成功；共 152 条；Cyber 的 required 里 7 个安全技能；API 排序 required → preferred → bonus
22:01	技能库 v2：建立 CSV 单一数据源，用脚本生成 SQL seed 和 NLP 用的 JSON；修掉 alias 冲突；新增 37 个技能；安全类技能改成 Technical	data/skills/、 database/seed_skills_library_v2.sql、 nlp/resources/skills_taxonomy.json、 tests/test_skills_library.py	pytest 8 个全过；seed 跑两次数量不变 (138)；v1 的 32 个技能没有改名
21:56	开工检查：同步 dev、开 feature/skills-library-v2 分支、测试数据库连接、确认 jobs.py 排序	docs/SPRINT2_SKILLS_DATASET_PLAN.md	数据库可连；jobs.py 已经按 CASE jrs.importance 排序，不用再改

测试账号：student0001 到 student5000@synthetic.example.com，密码 Seagas@2026。

Git 分支与 PR 状态

feature/skills-library-v2 已 push 到 GitHub，共 8 个 commit（每个 Phase 一个）。本机没有装 gh，所以 PR 要到网页上开。没有 push 到 dev 或 main。

分支	PR	状态
feature/skills-library-v2	待开 → dev	已 push，等开 PR 和 review。PR 描述已经写好（包括给 Carl 和 Aaron 的事项、组员重新导入步骤）

开 PR：github.com/j23039278-netizen/Group10_ProjectA/pull/new/feature/skills-library-v2

决定和需要确认的事

按计划里的默认做法执行（前几项开工时已确认），下面是还要找人确认的。

#	事项	现在的做法	找谁
1	category 怎么对应评估维度	同一领域放同一个 category：安全（实践 + 工具）全是 Technical，云（含 Serverless）全是 AI_Digital	Carl 确认 AI_Digital 的定义
2	要不要加 Business Analyst / DevOps / AI-ML Engineer 职位	这次不加，只在 PR 里提建议	Carl（job_roles 在 schema.sql）

#	事项	现在的做法	找谁
3	合成数据默认数量	5000, 演示集用 <code>--n 500</code> (已确认)	—
4	JD 数据来源	工具已经好, 等我提供 Kaggle 数据集和手动复制的 JD; API 采集放 Phase 6	我自己
5	全新数据库测试	用临时库 <code>seagas_db_fresh_test</code> 测, 测完已删, 本机 <code>seagas_db</code> 没动 (已确认)	—
6	新技能没有学习资源	PR 里附了 106 个 v2 技能清单, 安全和云优先	Aaron
7	合并后合成数据 UUID 会变	PR 里写了重新导入的步骤	全组

已知问题

Part 1 的三个问题里, 技能排序已经修好, 技能库太小的问题已解决。还剩下这些:

- **还没有真实 JD 数据:** `jd_dataset.csv` 和 60 条 gold 样本要等原始数据到了才能生成, 职位技能表也要按频率分析再调一次。
- **评分还是占位逻辑:** `assessments.py` 还没有按 `required / preferred / bonus` 加权。
- **组员的数据库是旧的:** 合并后要先跑 `delete_synthetic_data.sql` 再重新导入, 否则还是旧的合成数据。
- **本机没装 spaCy:** 频率分析找技能库没有的词时用的是 n-gram, 噪音较多; 装了 spaCy 和 `en_core_web_sm` 后会自动改用 noun chunks。

下一步

- ☐ 在 GitHub 网页上开 `feature/skills-library-v2` → `dev` 的 PR, 贴上写好的描述
- ☐ 找 Carl 确认 category 和维度怎么对应, 以及要不要加新职位
- ☐ 把新技能清单发给 Aaron, 请他优先补安全和云的学习资源
- ☐ 收集 JD: 下载 Kaggle 数据集 (记录 license) + 手动复制, 每个职位至少 30 条
- ☐ 跑 `ingest_jds.py` → `analyse_jd_skills.py`, 按 `role_skill_diff.csv` 调职位技能
- ☐ 生成 60 条 gold 样本并人工标注 (按 `ANNOTATION_GUIDE.md`)
- ☐ 开始做 NLP 模块: `nlp/extractor.py` 和 `nlp/matcher.py` (keyword、semantic、hybrid)

☐ Phase 6 (API 采集 JD) : 等 PR 合并后, 数据不够时再做

Weekly Reflection (29 Sep 2026)

Summary. I expanded the skills library from 32 to 138 skills and made one CSV the single source for the database seed and the NLP taxonomy. I also updated all 6 role templates, regenerated the 5,000 synthetic students against the new library, and built the JD dataset pipeline. Everything is on `feature/skills-library-v2`, waiting for a PR into `dev`.

What went well. Automated checks caught real problems before they reached the database. Examples: alias conflicts such as SQL → MySQL, a case-only duplicate (Numpy / NumPy), and a bcrypt salt that made the "reproducible" dataset differ on every run. Reading role skills straight from the seed keeps the synthetic ground truth and the scoring templates in sync.

Challenges. More core skills per role lowered the coverage of average and weak students, so I re-tuned the archetype probabilities to get back to about 90 / 70 / 40%. Choosing categories was harder than expected. A split domain, such as security practices in AI_Digital but security tools in Technical, makes dimension scores misleading.

Lessons. Keep one source of truth and generate everything else from it. Everyday words (Go, Excel, REST, Shell) need separate handling in keyword matching. Gold labels must come from a person, not from the system being evaluated.

Next week. Collect real JDs (at least 30 per role), tune role skills from the frequency analysis, annotate the gold set, and start the NLP extractor.